Análisis y clasificación de estrés agudo y actividad física a partir de datos fisiológicos mediante aprendizaje supervisado

Braulio S. Gutiérrez-Hernández
Algoritmos para Sistemas Inteligentes
Centro de Investigación Científica y de Educación Superior de Ensenada
Unidad Académica Tepic
Nayarit, México
braulio@cicese.edu.mx

***Resumen*—El estrés agudo y la actividad física generan respuestas fisiológicas diferenciadas que pueden registrarse mediante dispositivos portables (*wearables*). En este trabajo se analiza el conjunto de datos público *Wearable Device Dataset from Induced Stress and Structured Exercise Sessions*, disponible en PhysioNet, el cual contiene sesiones controladas de estrés agudo, ejercicio aeróbico y ejercicio anaeróbico.**

Se propone un flujo metodológico reproducible que incluye: (i) selección de señales con sustento fisiológico, (ii) preprocesamiento mínimo con manejo explícito de datos faltantes, (iii) extracción de 31 características interpretables en los dominios del tiempo y la frecuencia, y (iv) entrenamiento de un clasificador *Random Forest* para evaluar la separabilidad entre los tres estados.

El modelo obtuvo una exactitud de 0.95 en el conjunto de prueba y 0.9184 ± 0.0248 en validación cruzada estratificada de 5 *folds*. La clase AEROBIC se clasificó perfectamente ($F_1 = 1.00$), mientras que la única confusión observada ocurrió entre STRESS y ANAEROBIC. Las características más relevantes provinieron principalmente del acelerómetro y de la tasa de cambio de la aceleración (*jerk*), seguidas por variables cardiovasculares y de actividad electrodérmica.

***Palabras clave*—datos fisiológicos, estrés agudo, ejercicio aeróbico, ejercicio anaeróbico, aprendizaje supervisado, wearables, HRV, EDA, acelerometría**

I. Introducción

El monitoreo fisiológico mediante dispositivos portables (*wearables*) permite adquirir de forma continua y no invasiva señales asociadas al sistema nervioso autónomo y al movimiento corporal. Variables como la frecuencia cardíaca (HR), los intervalos entre latidos (IBI), la variabilidad de la frecuencia cardíaca (HRV), la actividad electrodérmica (EDA) y la acelerometría tri-axial (ACC) resultan útiles para caracterizar estados como el estrés y la actividad física, ya que reflejan mecanismos autonómicos y conductuales ampliamente documentados [7], [8].

Activación simpática y estrés. La respuesta al estrés agudo activa la rama simpática del sistema nervioso autónomo. Esto produce aumento de la frecuencia cardíaca, vasoconstricción y activación de las glándulas sudoríparas, al tiempo que disminuye la modulación parasimpática [8], [9]. Tales cambios se reflejan principalmente en señales cardiovasculares y en la EDA.

Superposición fisiológica con el ejercicio. Tanto el estrés como el ejercicio elevan la frecuencia cardíaca, aunque por mecanismos distintos: en el ejercicio, por demanda metabólica; en el estrés, por activación autonómica y psicológica. Si solo se analiza HR, ambas condiciones pueden confundirse. La acelerometría aporta contexto de movimiento y ayuda a distinguir el incremento cardiovascular asociado al esfuerzo físico del que ocurre en reposo durante una situación de estrés [4], [10].

II. Datos y marco experimental

Se emplea el conjunto de datos *Wearable Device Dataset from Induced Stress and Structured Exercise Sessions*, disponible en PhysioNet [2]. Este recurso contiene sesiones de estrés inducido, ejercicio aeróbico y ejercicio anaeróbico registradas con un *wearable* de muñeca que proporciona EDA, ACC tri-axial, temperatura periférica y señales cardiovasculares derivadas como HR, IBI y BVP [1].

El subconjunto utilizado comprende 98 sesiones: 36 de STRESS, 31 de AEROBIC y 31 de ANAEROBIC. Se aplicó una partición estratificada de $80/20$, lo que dio como resultado 78 muestras de entrenamiento y 20 de prueba. Esta configuración permite comparar estrés y ejercicio bajo el mismo protocolo y con los mismos sensores, lo que reduce sesgos asociados al hardware o a diferencias en el proceso de adquisición.

III. Trabajo relacionado

La detección de estrés y el reconocimiento de actividad física a partir de señales fisiológicas se han estudiado ampliamente, aunque la mayoría de los trabajos los aborda por separado. Esta revisión se organiza en cuatro ejes: (i) detección de estrés con *wearables*, (ii) variabilidad de la frecuencia cardíaca como marcador autonómico, (iii) reconocimiento de actividad física mediante acelerometría, y (iv) estudios que consideran la confusión entre ambos dominios.

A. Detección de estrés con wearables

El conjunto de datos WESAD de Schmidt *et al.* [3] es uno de los referentes más citados en detección multimodal

de estrés y afecto. Los autores combinaron un dispositivo en el pecho con otro en la muñeca y registraron EDA, BVP, temperatura y ACC durante condiciones de estrés inducido, estado base y diversión. La combinación de EDA y señales cardiovasculares superó el desempeño de cada modalidad por separado, alcanzando exactitudes de hasta el 93%. Sin embargo, WESAD no incluye ejercicio estructurado, por lo que no permite estudiar directamente la confusión entre estrés y esfuerzo físico.

Gjoreski *et al.* [4] abordaron la detección continua de estrés con el dispositivo Empatica E4, el mismo tipo de sensor utilizado en este proyecto. Su principal hallazgo fue que la actividad física genera una de las fuentes más importantes de falsas alarmas, ya que la frecuencia cardíaca puede aumentar durante el ejercicio de forma similar a como lo hace en situaciones de estrés. Para reducir esa confusión, los autores incorporaron la acelerometría como variable de contexto, lo que motivó directamente su uso en el presente trabajo.

B. Variabilidad de la frecuencia cardíaca como marcador autonómico

El Task Force de la Sociedad Europea de Cardiología [8] establece los estándares de medición e interpretación de la HRV, incluyendo métricas temporales como SDNN, RMSSD y pNN50, así como métricas espectrales basadas en bandas LF y HF. La HRV describe el balance simpático-parasimpático: el estrés psicológico tiende a reducirla por retiro vagal, mientras que el ejercicio de alta intensidad también la disminuye de manera progresiva [5]. Esto anticipa una posible superposición entre STRESS y ANAEROBIC cuando solo se consideran variables cardiovasculares.

C. Reconocimiento de actividad física con acelerometría

Twomey *et al.* [10] compararon diversos algoritmos de reconocimiento de actividad humana basados en acelerómetros. Sus resultados mostraron que la energía, la varianza de la magnitud y la distribución de percentiles del acelerómetro se encuentran entre las características más discriminativas para separar actividad estática y dinámica, así como distintos niveles de intensidad. Estos hallazgos respaldan el uso de las variables de ACC empleadas en este proyecto.

D. Trabajos que abordan estrés y ejercicio conjuntamente

Hongn *et al.* [1] publicaron el conjunto de datos utilizado aquí con el propósito de cubrir la brecha entre estudios de estrés y de ejercicio. El recurso incluye sesiones controladas de estrés inducido, ejercicio aeróbico y anaeróbico obtenidas con el mismo dispositivo y bajo el mismo protocolo. Aunque el trabajo documenta la calidad de las señales, no propone un *pipeline* completo de clasificación supervisada, por lo que el desarrollo y evaluación de dicho flujo constituyen una aportación directa del presente trabajo.

La Tabla I resume los trabajos revisados y su principal limitación respecto al escenario conjunto de estrés y ejercicio abordado en este estudio.

Tabla I
COMPARACIÓN DE TRABAJOS RELACIONADOS

Referencia	**Enfoque**	**Limitación principal**
Schmidt *et al.* [3]	Estrés/afecto multimodal	No incluye ejercicio estructurado.
Gjoreski *et al.* [4]	Estrés continuo en muñeca	La actividad física genera falsas alarmas sin ACC.
Task Force [8]	Estándares de HRV	Aporta marco metodológico, pero no clasificación.
Kim *et al.* [9]	Meta-análisis HRV-estrés	No incluye ejercicio como condición de confusión.
Hernando *et al.* [5]	HRV durante ejercicio	No incorpora estrés psicológico inducido.
Twomey *et al.* [10]	HAR con acelerómetro	No considera señales fisiológicas ni estrés.
Hongn *et al.* [1]	Estrés y ejercicio en mismo protocolo	No presenta un *pipeline* de clasificación.

IV. FUNDAMENTO FISIOLÓGICO Y JUSTIFICACIÓN DE SEÑALES

A. Frecuencia cardíaca e intervalos entre latidos

La frecuencia cardíaca HR refleja la carga cardiovascular y la activación autonómica global. Los intervalos entre latidos IBI constituyen su representación temporal directa. Si t_k denota el instante del k-ésimo latido, entonces:

$$\mathrm{IBI}_k = t_{k+1} - t_k, \quad k = 1, 2, \ldots, N-1. \tag{1}$$

La variabilidad de la frecuencia cardíaca (HRV) cuantifica las fluctuaciones de la serie $\{\mathrm{IBI}_k\}$ y describe la modulación autonómica del corazón. Dos métricas temporales estándar [8] son:

$$\mathrm{SDNN} = \sqrt{\frac{1}{N-1}\sum_{k=1}^{N}\left(\mathrm{IBI}_k - \overline{\mathrm{IBI}}\right)^2}, \tag{2}$$

$$\mathrm{RMSSD} = \sqrt{\frac{1}{N-1}\sum_{k=1}^{N-1}\left(\mathrm{IBI}_{k+1} - \mathrm{IBI}_k\right)^2}. \tag{3}$$

En condiciones de estrés psicológico suele observarse una reducción de HRV asociada al retiro vagal y al aumento de la actividad simpática [9]. Durante ejercicio intenso, la HRV también disminuye conforme aumenta el esfuerzo [5]. Esta coincidencia explica parte de la confusión entre STRESS y ANAEROBIC y justifica la inclusión de señales de movimiento.

B. Actividad electrodérmica

La actividad electrodérmica (EDA) es un marcador simpático sudomotor. Sus incrementos reflejan la activación de las glándulas sudoríparas mediada por la rama simpática del sistema nervioso autónomo [7]. Por ello se utiliza con frecuencia como indicador de activación fisiológica y estrés [3], [4].

Para extraer características espectrales se calcula la potencia de la señal mediante la Transformada Discreta de Fourier:

$$X[m] = \sum_{n=0}^{N-1} x[n]\, e^{-j2\pi mn/N}, \tag{4}$$

donde $x[n]$ representa la señal de EDA centrada en cero. La potencia relativa en una banda de frecuencias $[f_1, f_2)$ se define como:

$$P_{[f_1,f_2)} = \frac{\sum\limits_{m:\, f_m \in [f_1,f_2)} |X[m]|^2}{\sum\limits_{m=0}^{\lfloor N/2 \rfloor} |X[m]|^2 + \varepsilon}, \tag{5}$$

con $\varepsilon = 10^{-12}$ para estabilidad numérica. La banda $[0.1,\, 0.5]$ Hz resulta especialmente sensible a activaciones simpáticas lentas y por ello se emplea en tareas de detección de estrés [7].

C. Acelerometría y tasa de cambio de la aceleración

El acelerómetro tri-axial proporciona las componentes $a_x[n]$, $a_y[n]$ y $a_z[n]$ en función del índice de muestra n. La magnitud de la aceleración, independiente de la orientación del dispositivo, se calcula como:

$$\|\mathbf{a}[n]\| = \sqrt{a_x[n]^2 + a_y[n]^2 + a_z[n]^2}. \tag{6}$$

En mecánica clásica, el *jerk* representa la tasa de cambio de la aceleración con respecto al tiempo. En forma continua se expresa como:

$$\mathbf{j}(t) = \frac{d\mathbf{a}(t)}{dt}, \tag{7}$$

y en forma discreta, aplicada sobre la magnitud de la aceleración, se aproxima mediante diferencias finitas de primer orden:

$$j[n] = \|\mathbf{a}[n+1]\| - \|\mathbf{a}[n]\|, \quad n = 0, 1, \ldots, N-2. \tag{8}$$

El *jerk* permite capturar cambios bruscos de movimiento entre muestras consecutivas. Esta variable resulta útil porque el ejercicio anaeróbico suele presentar transiciones más abruptas entre actividad intensa y reposo, mientras que el ejercicio aeróbico tiende a mostrar un movimiento más estable y el estrés en reposo valores cercanos a cero [10].

V. Metodología

La Figura 1 muestra el flujo general del procesamiento, desde la lectura de los archivos CSV hasta la evaluación del modelo.

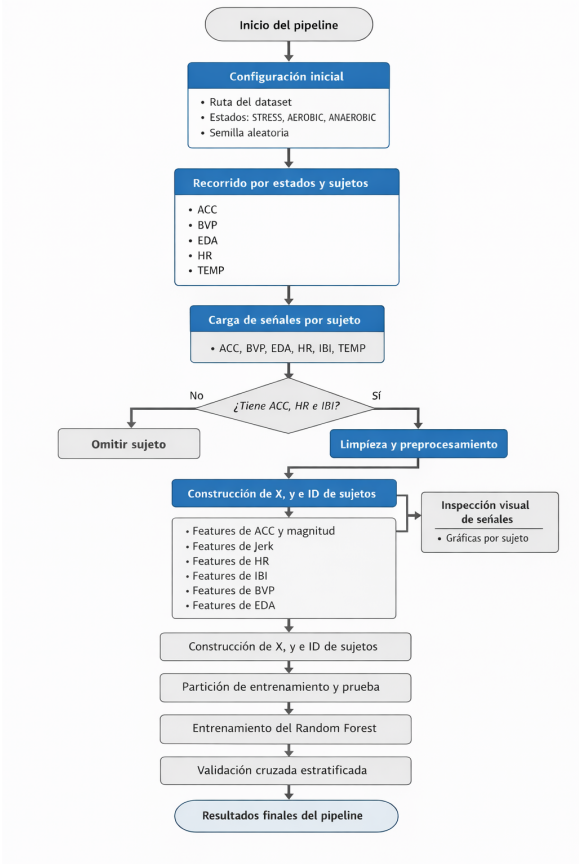

Figura 1. Diagrama de flujo del *pipeline* de procesamiento.

A. Preprocesamiento

Se aplicó un preprocesamiento mínimo orientado a mantener representaciones consistentes entre sesiones:

- **Lectura robusta:** los archivos CSV contienen la frecuencia de muestreo f_s en la primera fila y las muestras a partir de la tercera. Las señales multicolumna, como ACC tri-axial e IBI con marca de tiempo, se procesan de forma diferenciada.
- **Manejo de datos faltantes:** se excluyen las sesiones que no contienen ACC, IBI o HR, ya que estas señales se consideran obligatorias para construir el vector de características.
- **Consistencia de dimensionalidad:** se genera un vector de longitud fija $d = 31$ por sesión; cuando una característica no puede calcularse por insuficiencia de señal, se asigna el valor 0.0.

B. Extracción de características

Se extrajeron 31 características distribuidas en cinco grupos de señales, seleccionadas por su interpretabilidad fisiológica

y por su capacidad para distinguir entre los tres estados analizados.

1) Variabilidad dinámica del acelerómetro por eje: La media de las diferencias absolutas entre muestras consecutivas (*madiff*) para el eje $u \in \{x, y, z\}$ cuantifica la variabilidad dinámica del movimiento en esa dirección:

$$\mu_{\Delta,u} = \frac{1}{N-1} \sum_{n=0}^{N-2} |a_u[n+1] - a_u[n]|. \tag{9}$$

Durante ejercicio aeróbico, el movimiento suele ser rítmico y sostenido, por lo que $\mu_{\Delta,u}$ tiende a ser alta y relativamente estable. En ejercicio anaeróbico el movimiento suele ser más explosivo e intermitente, lo que genera valores altos con mayor dispersión. En estrés, el sujeto permanece en reposo o con movimiento mínimo, por lo que $\mu_{\Delta,u}$ disminuye notablemente en los tres ejes [10].

Además, la raíz cuadrática media del eje y cuantifica la energía del movimiento vertical:

$$\text{RMS}_y = \sqrt{\frac{1}{N} \sum_{n=0}^{N-1} a_y[n]^2}, \tag{10}$$

mientras que la tasa de cruces por cero del eje x mide la frecuencia con que la señal cambia de signo:

$$\text{ZCR}_x = \frac{1}{N-1} \sum_{n=0}^{N-2} \mathbf{1}\big[\tilde{a}_x[n+1] \cdot \tilde{a}_x[n] < 0\big], \tag{11}$$

donde $\tilde{a}_x[n] = a_x[n] - \bar{a}_x$ es la señal centrada y $\mathbf{1}[\cdot]$ es la función indicadora.

2) Magnitud del acelerómetro y estructura del movimiento: A partir de la serie $\|\mathbf{a}[n]\|$ se extraen estadísticos que describen la intensidad global y la estructura temporal del movimiento sin depender de la orientación del dispositivo [10]:

- $\mu_{\Delta,\text{mag}}$: *madiff* de la magnitud.
- $\text{IQR}_{\text{mag}} = Q_{75} - Q_{25}$: rango intercuartil.
- $Q_{90,\text{mag}}$: percentil 90.
- $\hat{\beta}_{\text{mag}}$: pendiente por mínimos cuadrados.
- N_{picos}: número de máximos locales por encima del umbral.
- $\rho_{\text{picos}} = N_{\text{picos}}/N$: densidad de picos por muestra.

3) Tasa de cambio de la aceleración (jerk): De la serie $j[n]$ definida en la ecuación (8) se extraen seis estadísticos de orden que describen la distribución de los cambios bruscos de movimiento:

$$\mathcal{J} = \big\{Q_{10}^j,\ Q_{25}^j,\ Q_{75}^j,\ Q_{90}^j,\ \text{IQR}^j,\ \mu_\Delta^j\big\}. \tag{12}$$

El ejercicio anaeróbico tiende a producir valores más extremos y una dispersión mayor en el *jerk*. El ejercicio aeróbico sostenido genera valores más acotados alrededor de cero, mientras que el estrés en reposo presenta una distribución mucho más cercana a cero [10].

4) Frecuencia cardíaca e intervalos entre latidos: De la señal de HR se extraen la media $\overline{\text{HR}}$ y la *madiff* $\mu_{\Delta,\text{HR}}$. Aunque el ejercicio y el estrés elevan la frecuencia cardíaca, lo hacen con magnitudes y patrones distintos: el ejercicio anaeróbico suele alcanzar los valores más altos, el aeróbico valores altos pero más estables, y el estrés incrementos moderados en reposo [8].

De la serie IBI se extraen la media $\overline{\text{IBI}}$, el mínimo IBI_{min} y tres percentiles inferiores:

$$\mathcal{I} = \big\{\overline{\text{IBI}},\ \text{IBI}_{\text{min}},\ Q_{10}^{\text{IBI}},\ Q_{10}^t,\ Q_{25}^t\big\}. \tag{13}$$

5) Pulso de volumen sanguíneo y actividad electrodérmica: Del BVP se extraen la tasa de cruces por cero ZCR_{BVP}, el número de picos $N_{\text{picos}}^{\text{BVP}}$ y la mediana $\tilde{x}_{\text{BVP}}$.

De la EDA se extrae la potencia relativa en la banda $[0.1,\ 0.5]$ Hz, calculada según la ecuación (5):

$$P_{\text{EDA}} = P_{[0.1,\,0.5]}. \tag{14}$$

La Tabla II resume las 31 características, su señal de origen y la razón general por la que contribuyen a la discriminación entre estados.

Tabla II
CARACTERÍSTICAS EXTRAÍDAS (31 EN TOTAL) Y FUNDAMENTO DISCRIMINATIVO

Señal	Características	Por qué discrimina
ACC (ejes)	$\mu_{\Delta,x}$, $\mu_{\Delta,y}$, $\mu_{\Delta,z}$, RMS_y, energía$_y$, $Q_{90,y}$, ZCR_x	Capturan nivel, dirección e intermitencia del movimiento; en STRESS suelen tomar valores bajos [10].
ACCMAG	$\mu_{\Delta,\text{mag}}$, IQR_{mag}, $Q_{90,\text{mag}}$, $\hat{\beta}_{\text{mag}}$, N_{picos}, ρ_{picos}	Describen intensidad global del movimiento sin depender de la orientación del sensor [10].
Jerk $j[n]$	Q_{10}^j, Q_{25}^j, Q_{75}^j, Q_{90}^j, IQR^j, μ_Δ^j	Reflejan transiciones bruscas de movimiento y ayudan a diferenciar AEROBIC de ANAEROBIC [10].
HR / IBI	$\overline{\text{HR}}$, $\mu_{\Delta,\text{HR}}$, $\overline{\text{IBI}}$, IBI_{min}, Q_{10}^{IBI}, Q_{10}^t, Q_{25}^t	Describen carga cardiovascular y variabilidad temporal; complementan la información de movimiento [8], [9].
BVP / EDA	ZCR_{BVP}, $N_{\text{picos}}^{\text{BVP}}$, $\tilde{x}_{\text{BVP}}$, P_{EDA}	Aportan información sobre perfusión periférica y activación simpática, relevante sobre todo en casos ambiguos [7].

C. Clasificación supervisada

El problema se formula como:

$$f : \mathbb{R}^{31} \to \{\text{STRESS, AEROBIC, ANAEROBIC}\}. \tag{15}$$

Se entrena un clasificador *Random Forest* [11] con los hiperparámetros de la Tabla III. La opción `class_weight=balanced` asigna a cada árbol un peso inversamente proporcional a la frecuencia de cada clase y ayuda a compensar el leve desbalance entre ellas (36 STRESS, 31 AEROBIC y 31 ANAEROBIC).

Tabla III
HIPERPARÁMETROS DEL CLASIFICADOR *Random Forest*

Hiperparámetro	**Valor**
Número de árboles	300
Características evaluadas por división	$\lfloor \log_2(31) \rfloor = 4$
Mínimo de muestras para dividir	6
Profundidad máxima	Sin límite
Ponderación de clases	Balanceada

D. Métricas de evaluación

Se reportan exactitud (*accuracy*), precisión, sensibilidad (*recall*) y F_1-*score* por clase, además de la matriz de confusión. Para estimar la estabilidad del desempeño se realizó validación cruzada estratificada de 5 *folds* (CV-5), cuya exactitud promedio se expresa como $\mu \pm \sigma$.

VI. RESULTADOS Y DISCUSIÓN

A. Desempeño cuantitativo

El conjunto final quedó conformado por 98 muestras y 31 características. Tras la partición estratificada, se utilizaron 78 muestras para entrenamiento y 20 para prueba. El modelo alcanzó una exactitud de 0.95 en el conjunto de prueba.

La Tabla IV presenta las métricas por clase. AEROBIC se clasificó perfectamente ($F_1 = 1.00$), mientras que ANAEROBIC y STRESS alcanzaron valores de F_1 de 0.92 y 0.93, respectivamente.

Tabla IV
MÉTRICAS POR CLASE EN EL CONJUNTO DE PRUEBA (20 MUESTRAS)

Clase	**Precisión**	**Sensibilidad**	$\boldsymbol{F_1}$	**Soporte**
AEROBIC	1.00	1.00	1.00	6
ANAEROBIC	0.86	1.00	0.92	6
STRESS	1.00	0.88	0.93	8
Promedio macro	0.95	0.96	0.95	20
Promedio ponderado	0.96	0.95	0.95	20

La validación cruzada estratificada de 5 *folds* produjo una exactitud promedio de:

$$\text{Accuracy}_{\text{CV}} = 0.9184 \pm 0.0248, \tag{16}$$

con puntuaciones por *fold* de $[0.9000,\ 0.9000,\ 0.9500,\ 0.8947,\ 0.9474]$. Estos valores muestran un comportamiento estable y sugieren que el modelo no depende de una partición particularmente favorable.

B. Matriz de confusión

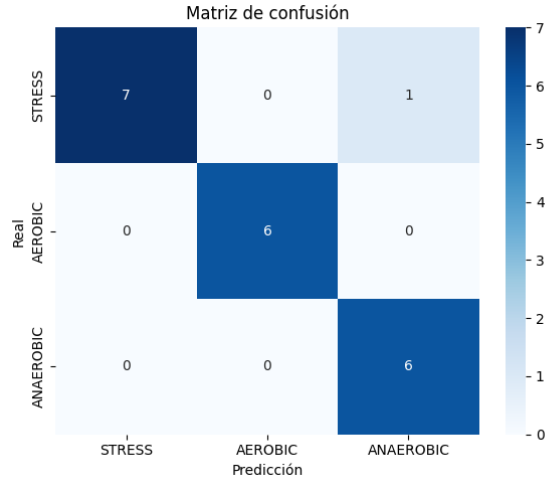

Figura 2. Matriz de confusión del modelo *Random Forest* en el conjunto de prueba.

La Figura 2 muestra que la única confusión ocurrió en una muestra de STRESS clasificada como ANAEROBIC. No se observaron errores en la clase AEROBIC ni en las seis muestras reales de ANAEROBIC. Este patrón es coherente con la cercanía fisiológica entre el estrés y ciertas fases del ejercicio anaeróbico, especialmente cuando la actividad del acelerómetro disminuye pero la respuesta cardiovascular permanece elevada.

C. Importancia de características

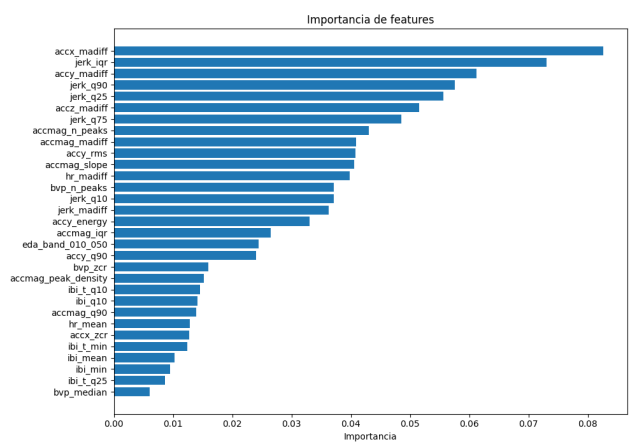

Figura 3. Importancia de características según el modelo *Random Forest*.

La Figura 3 presenta la importancia relativa de las 31 características. Las diez variables con mayor contribución fueron:

1) `accx_madiff` (0.0826)
2) `jerk_iqr` (0.0731)
3) `accy_madiff` (0.0612)
4) `jerk_q90` (0.0575)

5) `jerk_q25` (0.0556)
6) `accz_madiff` (0.0516)
7) `jerk_q75` (0.0485)
8) `accmag_n_peaks` (0.0430)
9) `accmag_madiff` (0.0409)
10) `accy_rms` (0.0408)

El predominio de características derivadas del acelerómetro y del *jerk* indica que el movimiento constituye la fuente principal de información para separar los tres estados. Las variables cardiovasculares y de EDA también aportan valor, pero en este experimento operan más como apoyo para resolver casos ambiguos que como discriminadores principales.

D. Discusión fisiológica

El desempeño perfecto en AEROBIC sugiere que esta clase presenta un patrón bien definido: movimiento sostenido, menor intermitencia que en el ejercicio anaeróbico y un perfil cardiovascular consistente. Esta combinación facilita su separación respecto a las otras dos clases.

La principal dificultad del modelo aparece entre STRESS y ANAEROBIC. Desde el punto de vista fisiológico, esto resulta razonable. Durante la recuperación entre esfuerzos anaeróbicos, la señal de movimiento puede disminuir de forma considerable mientras la frecuencia cardíaca sigue elevada, generando un perfil similar al de una respuesta de estrés. Por ello, aunque el modelo logró un desempeño alto, esta frontera sigue siendo la más difícil de resolver con el conjunto actual de características globales por sesión.

VII. Conclusiones

En este trabajo se desarrolló un *pipeline* completo para clasificar estados fisiológicos a partir de señales registradas con un dispositivo *wearable*. El proceso integró lectura de datos, preprocesamiento, extracción de características y clasificación supervisada en una misma metodología reproducible.

Los resultados obtenidos muestran que las señales fisiológicas y de movimiento permiten diferenciar de manera efectiva entre estrés agudo, ejercicio aeróbico y ejercicio anaeróbico. En particular, las variables derivadas del acelerómetro y del *jerk* fueron las más importantes para la clasificación, lo que confirma que el contexto de movimiento es clave para interpretar adecuadamente las respuestas cardiovasculares.

Aunque el desempeño global fue alto, la principal ambigüedad se presentó entre STRESS y ANAEROBIC, lo cual coincide con la superposición fisiológica entre ambos estados. Como trabajo futuro, sería conveniente incorporar métricas más específicas de HRV, análisis por ventanas temporales y comparación con otros clasificadores para fortalecer la capacidad de generalización del sistema.

VIII. Cronograma

Tabla V
Cronograma del proyecto

Periodo	**Actividad realizada / a realizar**
Enero (sem. 3–4)	Selección del tema y revisión bibliográfica.
Febrero (sem. 1)	Descarga del conjunto de datos y análisis de su documentación.
Febrero (sem. 2)	Visualización y análisis exploratorio de señales.
Febrero (sem. 3)	Preprocesamiento y manejo de datos faltantes.
Febrero (sem. 4)	Extracción de 31 características con sustento fisiológico.
Marzo (sem. 1)	Implementación del modelo base (*Random Forest*).
Marzo (sem. 2)	Evaluación, validación cruzada y análisis de importancia.
Marzo (sem. 3)	Discusión de resultados y comparación con el estado del arte.
Abril (sem. 1)	Redacción de resultados finales.
Abril (sem. 2)	Integración del documento final.
Abril (sem. 3)	Preparación de la presentación.

Referencias

[1] A. Hongn, F. Bosch, L. E. Prado, J. M. Ferrández y M. P. Bonomini, "Wearable Physiological Signals under Acute Stress and Exercise Conditions," *Scientific Data*, vol. 12, no. 1, 2025.

[2] A. Hongn, F. Bosch, L. E. Prado, J. M. Ferrández y M. P. Bonomini, "Wearable Device Dataset from Induced Stress and Structured Exercise Sessions," PhysioNet, 2025.

[3] P. Schmidt, A. Reiss, R. Duerichen, C. Marberger y K. Van Laerhoven, "Introducing WESAD, a Multimodal Dataset for Wearable Stress and Affect Detection," *Proc. ACM IMWUT*, vol. 2, no. 1, 2018.

[4] S. Gjoreski, M. Gjoreski, H. Luštrek y M. Gams, "Continuous Stress Detection Using a Wrist Device," *IEEE Trans. Affective Computing*, vol. 7, no. 4, pp. 409–421, 2016.

[5] A. Hernando, J. Lázaro, A. Gil *et al.*, "Decrease of heart rate variability during exercise," *PLOS ONE*, vol. 13, no. 7, 2018.

[6] A. L. Goldberger, L. A. N. Amaral, L. Glass *et al.*, "PhysioBank, PhysioToolkit, and PhysioNet: Components of a New Research Resource for Complex Physiologic Signals," *Circulation*, vol. 101, no. 23, pp. e215–e220, 2000.

[7] W. Boucsein, *Electrodermal Activity*, 2nd ed. Springer, 2012.

[8] Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology, "Heart rate variability: Standards of measurement, physiological interpretation and clinical use," *Circulation*, vol. 93, no. 5, pp. 1043–1065, 1996.

[9] H. G. Kim, E. J. Cheon, D. S. Bai, Y. H. Lee, y B. H. Koo, "Stress and Heart Rate Variability: A Meta-Analysis and Review of the Literature," *Psychiatry Investigation*, vol. 15, no. 3, pp. 235–245, 2018.

[10] N. Twomey, T. Diethe, X. Fafoutis *et al.*, "A Comprehensive Study of Activity Recognition Using Accelerometers," *Big Data and Cognitive Computing*, vol. 2, no. 2, 2018.

[11] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, pp. 5–32, 2001.